Université Sultan Moulay Slimane
École Nationale des Sciences Appliquées de Khouribga

Filière : Informatique et Ingénierie des Données

Module : Traitement de Données

Rapport de projet

Audit Data — Marketplace Olist

Analyse exploratoire d'une marketplace e-commerce brésilienne
(96 252 commandes — Période 2016–2018)

Réalisé par :

— Maktou Azeddine
— Nougbolo Godwin Elie

Encadré par :

Pr. Soukaina El Harouri

Année universitaire : 2025–2026

Résumé

Ce rapport présente une analyse complète du dataset *Brazilian E-Commerce Public Dataset by Olist*. Ce dataset contient neuf tables et plus de 100 000 commandes passées entre septembre 2016 et août 2018. Nous avons suivi quatre étapes : exploration des données, nettoyage et construction d'une table finale de 96 252 lignes, calcul des indicateurs, puis analyses détaillées selon cinq axes.

Les résultats principaux montrent un chiffre d'affaires total de 13,19 millions de BRL et une note moyenne de 4,16/5. Le résultat le plus important est la différence de satisfaction entre les commandes livrées à temps (4,29/5) et celles livrées en retard (2,27/5). Deux vendeurs avec de mauvaises évaluations et des taux de retard élevés ont aussi été identifiés.

Mots-clés : e-commerce, analyse de données, satisfaction client, logistique, Python, Pandas.

Remerciements. Nous remercions Pr. Soukaina El Harouri pour son encadrement et ses conseils, ainsi que l'équipe pédagogique de la filière IID1.

Table des matières

Résumé **1**

Introduction **3**

1 Présentation du dataset et nettoyage **4**
1.1 Structure et composition du dataset 4
1.1.1 Source et contexte 4
1.1.2 Tables disponibles 4
1.2 Nettoyage des données 4
1.2.1 Approche générale 4
1.2.2 Construction de la table finale 5

2 Indicateurs et analyse globale **6**
2.1 Indicateurs construits 6
2.2 Chiffres clés de la marketplace 6
2.3 Évolution mensuelle du chiffre d'affaires 6
2.4 Répartition géographique et top catégories 7

3 Analyses métier approfondies **9**
3.1 Satisfaction client 9
3.1.1 Impact du retard sur la note 9
3.1.2 Impact de la durée de livraison 9
3.2 Logistique et livraison 10
3.2.1 Taux de retard et délais 10
3.2.2 Impact de la distance vendeur-client 10
3.3 Analyse des vendeurs 11
3.3.1 Score vendeur composite 11
3.3.2 Vendeurs à surveiller 11
3.4 Analyse des catégories de produits 11
3.4.1 Catégories performantes 11
3.4.2 Catégories problématiques 11
3.4.3 Catégories à surveiller 12
3.4.4 Catégories à développer 12

4 Synthèse et recommandations **13**
4.1 Trois problèmes principaux 13
4.2 Recommandations 13
4.3 KPIs de suivi mensuel 13
4.4 Limites de l'analyse 13

Conclusion **15**

Introduction

Le commerce en ligne se développe rapidement dans les pays émergents. Au Brésil, des plateformes comme Olist permettent à des milliers de petits vendeurs de vendre leurs produits à des clients dans tout le pays. Ce projet fait partie du module Traitement de Données de la filière IID1 à l'ENSA Khouribga.

Notre objectif est d'analyser le dataset *Brazilian E-Commerce Public Dataset by Olist*, disponible sur Kaggle. Ce dataset contient neuf tables et plus de 100 000 commandes. Nous avons travaillé en quatre étapes : préparer les données, calculer des indicateurs, faire une analyse globale, puis approfondir l'analyse selon plusieurs axes métier.

1. Présentation du dataset et nettoyage

1.1 Structure et composition du dataset

1.1.1 Source et contexte

Le dataset utilisé est le *Brazilian E-Commerce Public Dataset by Olist*, disponible sur Kaggle. Il contient des commandes passées entre septembre 2016 et août 2018, avec des informations sur les clients, les vendeurs, les produits, les paiements et les avis.

1.1.2 Tables disponibles

Le dataset est organisé en neuf tables (tableau 1.1). La table `orders` est la table principale ; toutes les autres sont reliées à elle via des clés étrangères (figure 1.1).

TABLE 1.1 – Composition du dataset Olist

Table	Description	Lignes	Rôle
`orders`	Commandes	99 441	Table centrale
`customers`	Clients	99 441	Données client
`items`	Articles par commande	112 650	Prix et frais
`products`	Catalogue produits	32 951	Infos produit
`sellers`	Vendeurs	3 095	Données vendeur
`payments`	Paiements	103 886	Données financières
`reviews`	Avis clients	99 224	Satisfaction
`geolocation`	Coordonnées GPS	1 000 163	Géographie
`translations`	Traductions catégories	71	Référentiel

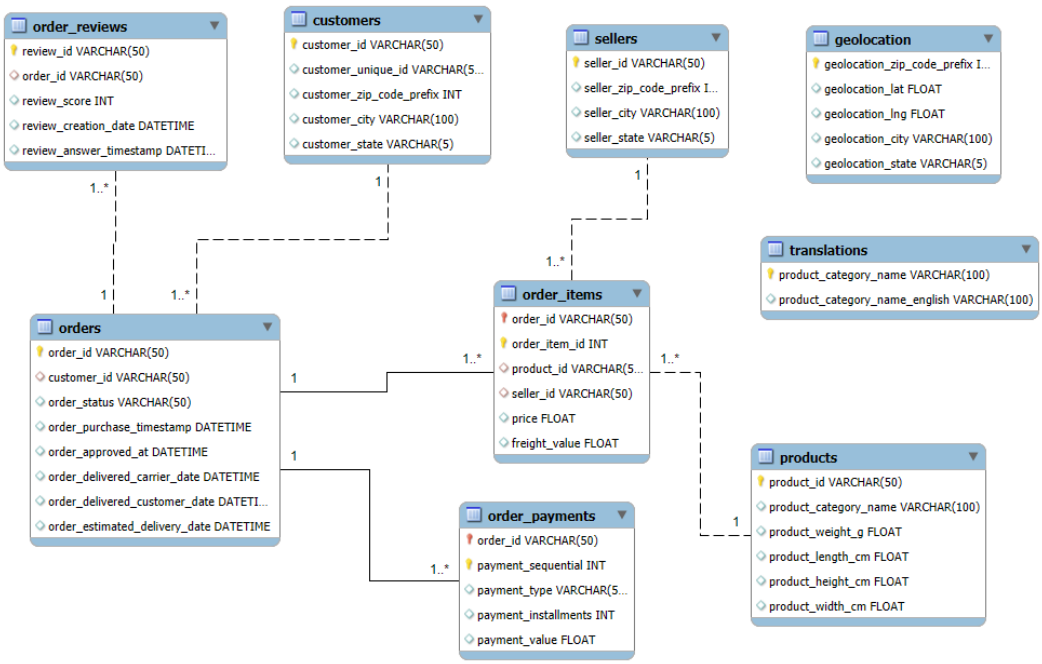


FIGURE 1.1 – Schéma des relations entre les neuf tables du dataset

1.2 Nettoyage des données

1.2.1 Approche générale

Nous avons nettoyé chaque table en suivant quatre étapes : suppression des doublons, traitement des valeurs manquantes, correction des types de données, et vérification des valeurs

incorrectes. Le tableau 1.2 résume les opérations effectuées.

TABLE 1.2 – Bilan du nettoyage par table

Table	Opérations principales
`orders`	Suppression de 166 lignes avec des dates incohérentes (livraison avant le transport). Les valeurs manquantes sur certaines dates ont été conservées.
`items`	383 lignes avec des frais de livraison nuls ont été identifiées et conservées avec la valeur 0.
`reviews`	Suppression de 814 doublons sur `review_id` et de 243 avis en double par commande.
`products`	610 valeurs manquantes sur les champs descriptifs conservées. Les catégories sans traduction ont été remplacées par `desconhecido`.
`payments`	3 lignes avec `payment_type = not_defined` identifiées, sans impact sur les calculs financiers.

1.2.2 Construction de la table finale

La table finale a été construite en joignant plusieurs tables, en gardant uniquement les commandes au statut `delivered`. Les commandes annulées ou en cours ont été exclues.

TABLE 1.3 – Suivi des lignes lors de la construction de la table finale

Étape	Lignes
Commandes au statut `delivered`	96 313
Après les six jointures (clients, articles, paiements, avis, vendeurs, produits)	96 313
Après suppression des dates incohérentes restantes	96 252
Table finale — 30 colonnes	**96 252**

Aucune ligne n'a été perdue lors des jointures, ce qui confirme que les clés sont cohérentes. Les 61 lignes supprimées correspondent à des commandes dont la date d'approbation est après la date de livraison, ce qui est impossible.

2. Indicateurs et analyse globale

2.1 Indicateurs construits

Nous avons calculé quatre types d'indicateurs : des indicateurs financiers (`montant_total`, panier moyen et médian), des indicateurs de délai (`delai_livraison` en jours, indicateur de retard oui/non), des indicateurs temporels (mois, année), et des indicateurs de satisfaction (note moyenne, taux de notes faibles, score vendeur).

2.2 Chiffres clés de la marketplace

TABLE 2.1 – Indicateurs globaux de la marketplace Olist (2016–2018)

Indicateur	**Valeur**
Chiffre d'affaires total	13 195 594 BRL
Nombre de commandes analysées	96 252
Panier moyen	159,88 BRL
Panier médian	105,28 BRL
Note moyenne globale	4,16 / 5
Taux de retard global	6,8 %
Délai moyen de livraison	12,1 jours
Délai médian de livraison	10,0 jours
Taux de notes faibles (≤ 2)	12,8 %

Le panier médian (105,28 BRL) est plus bas que le panier moyen (159,88 BRL) parce que quelques commandes à très haute valeur (maximum 13 664 BRL) font monter la moyenne. Le panier médian représente mieux le comportement d'achat habituel.

2.3 Évolution mensuelle du chiffre d'affaires

Le chiffre d'affaires augmente régulièrement sur 23 mois. Le pic est en novembre 2017 (987 765 BRL), ce qui correspond au Black Friday au Brésil. En 2018, plusieurs mois dépassent 900 000 BRL. La figure 2.1 montre aussi la répartition par catégorie et la distribution des montants par commande.

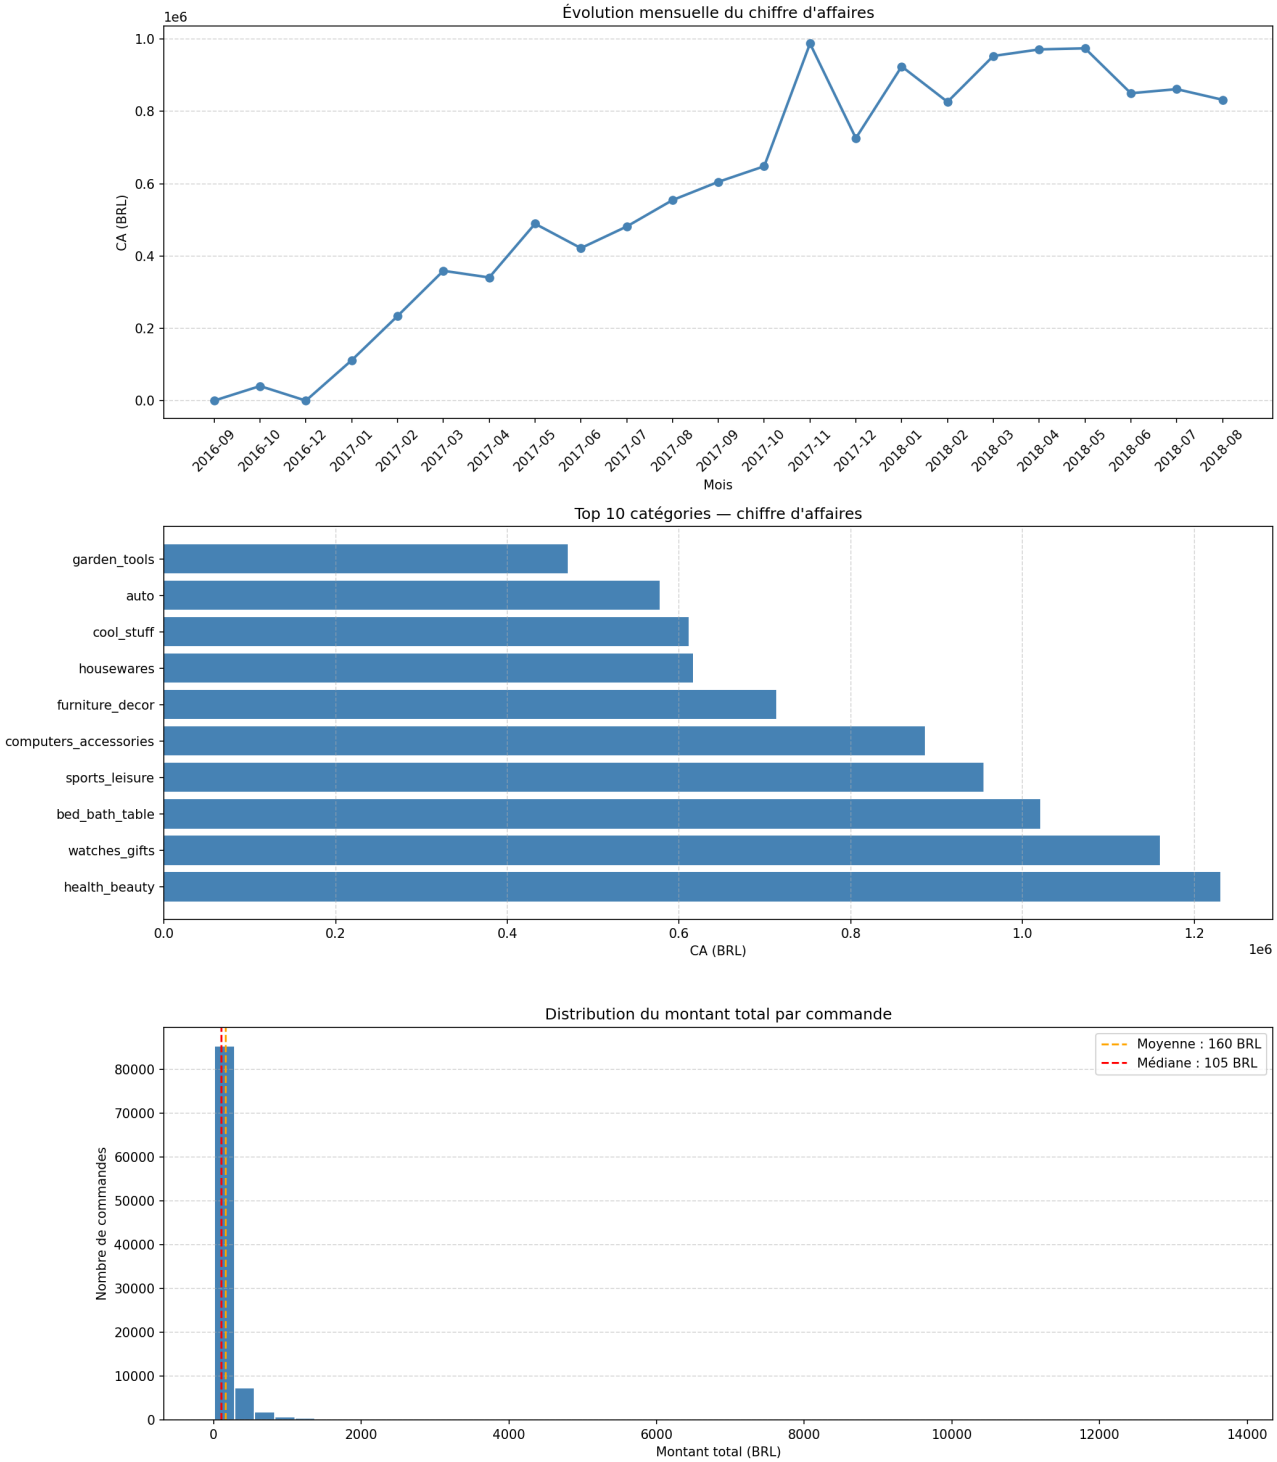


FIGURE 2.1 – Évolution mensuelle du CA, top catégories et distribution du montant total

2.4 Répartition géographique et top catégories

São Paulo (SP) représente 38,3 % du CA, suivi de Rio de Janeiro (13,3 %) et Minas Gerais (11,7 %). Ces trois états représentent plus de 63 % du CA total. Les états du sud (RS, PR, SC) représentent environ 15 % de plus. La figure 2.2 montre cette concentration, et le tableau 2.2 présente les dix premières catégories, qui représentent environ 56 % du CA.

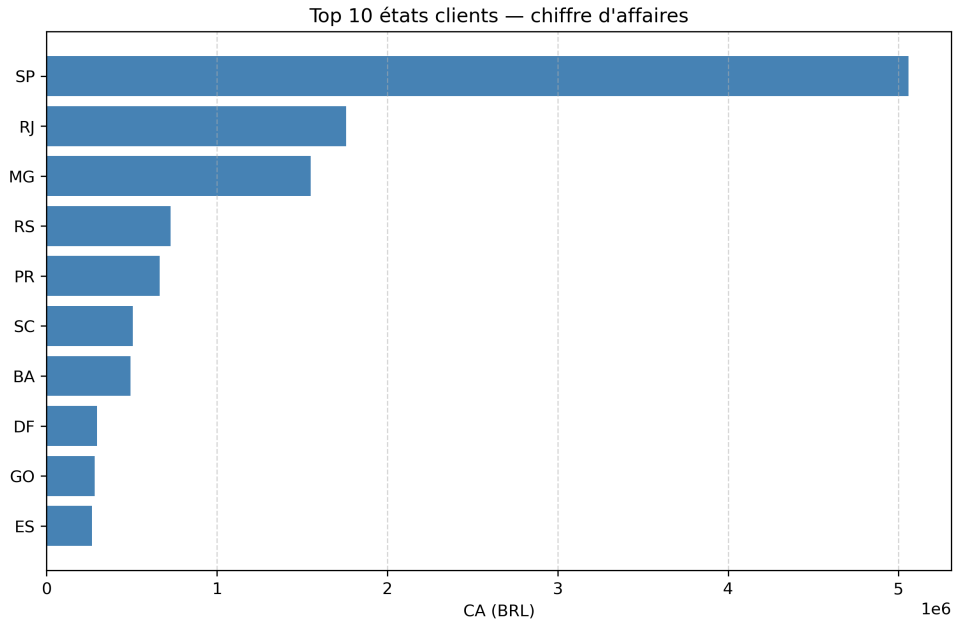


FIGURE 2.2 – Top 10 états clients par chiffre d'affaires

TABLE 2.2 – Top 10 catégories par chiffre d'affaires

Catégorie	**CA (BRL)**	**Part (%)**
health_beauty	1 229 975	9,3
watches_gifts	1 159 859	8,8
bed_bath_table	1 020 478	7,7
sports_leisure	954 115	7,2
computers_accessories	886 218	6,7
furniture_decor	712 811	5,4
housewares	615 908	4,7
cool_stuff	611 047	4,6
auto	577 592	4,4
garden_tools	470 312	3,6

3. Analyses métier approfondies

Dans cette partie, nous analysons cinq axes : la satisfaction client, la logistique, les vendeurs, les catégories de produits et la géographie.

3.1 Satisfaction client

3.1.1 Impact du retard sur la note

TABLE 3.1 – Note moyenne selon le statut de livraison

Statut de livraison	Note moyenne
À temps	4,29 / 5
En retard	2,27 / 5

La différence de deux points montre que le retard est le facteur le plus important dans la baisse de satisfaction (figure 3.1).

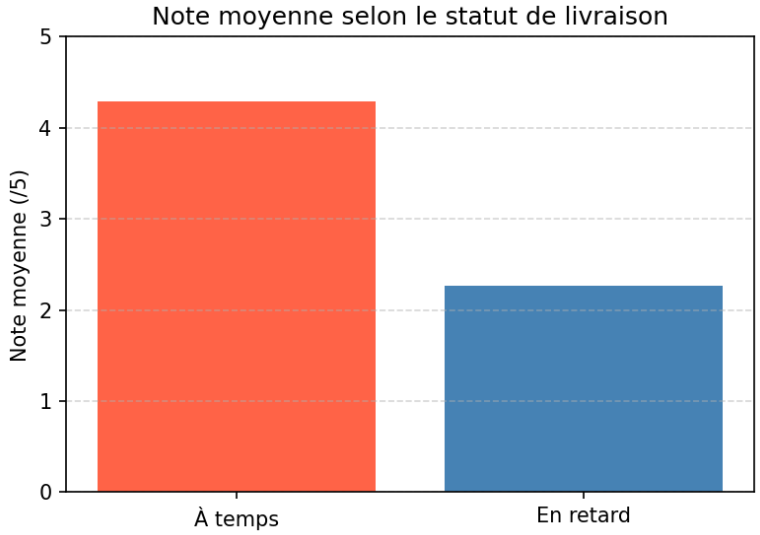


FIGURE 3.1 – Note moyenne selon le statut de livraison

3.1.2 Impact de la durée de livraison

L'analyse par tranches de délai montre que plus la livraison est longue, plus la note baisse. Cela est vrai même pour les commandes arrivées avant la date prévue (figure 3.2).

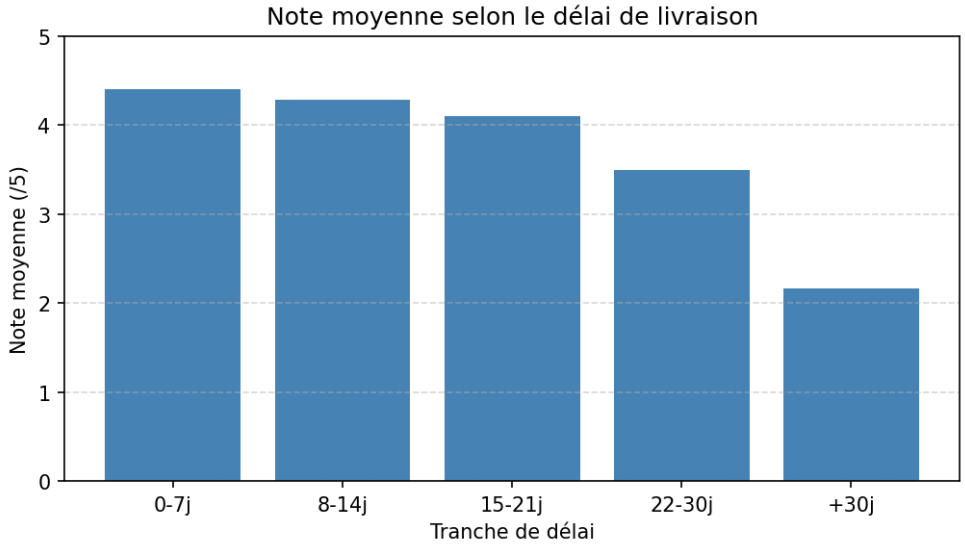


FIGURE 3.2 – Note moyenne par tranche de délai de livraison

3.2 Logistique et livraison

3.2.1 Taux de retard et délais

Sur 96 252 commandes, 6 531 ont été livrées après la date prévue, soit un taux de **6,8 %**. Le délai moyen est de 12,1 jours (médiane : 10 jours), avec des valeurs entre 0 et 209 jours.

3.2.2 Impact de la distance vendeur-client

TABLE 3.2 – Comparaison livraison : même état vs états différents

Configuration	Taux de retard	Délai moyen	Note moy.
Même état	4,5 %	7,5 jours	4,26
États différents	8,1 %	14,7 jours	4,10

Quand le vendeur et le client sont dans des états différents, le taux de retard double et le délai moyen est presque deux fois plus long. Les produits très lourds (plus de 5 kg) ont aussi un taux de retard plus élevé (7,9 %) que les produits légers (6,4 %). La figure 3.3 montre les états les plus touchés.

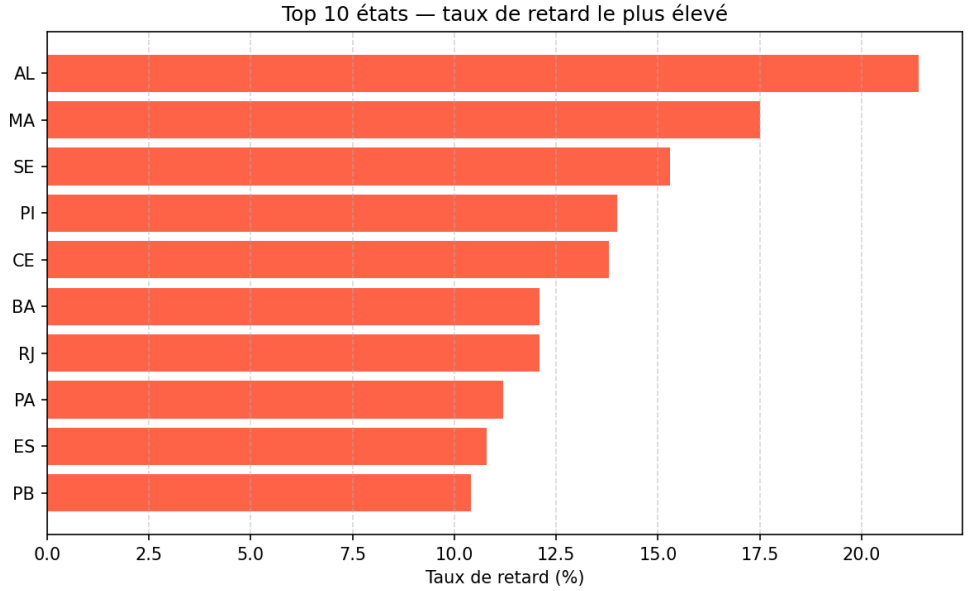


FIGURE 3.3 – Taux de retard par état client (top 10)

3.3 Analyse des vendeurs

3.3.1 Score vendeur composite

Nous avons calculé un score pour chaque vendeur actif (au moins 5 ventes), en combinant la note moyenne et le taux de retard. La plupart des 2 952 vendeurs scorés obtiennent de bons résultats : médiane de 8,97/10, moyenne de 8,76/10.

3.3.2 Vendeurs à surveiller

Deux vendeurs actifs (au moins 20 ventes) ont une note moyenne inférieure à 3 (tableau 3.3). Ils doivent être traités en priorité.

TABLE 3.3 – Vendeurs à surveiller (identifiants abrégés)

Identifiant (abrégé)	Nb ventes	CA (BRL)	Note moy.	Taux retard
1ca7077d…	108	12 544	2,39	16,7 %
2eb70248…	185	38 851	2,78	11,4 %

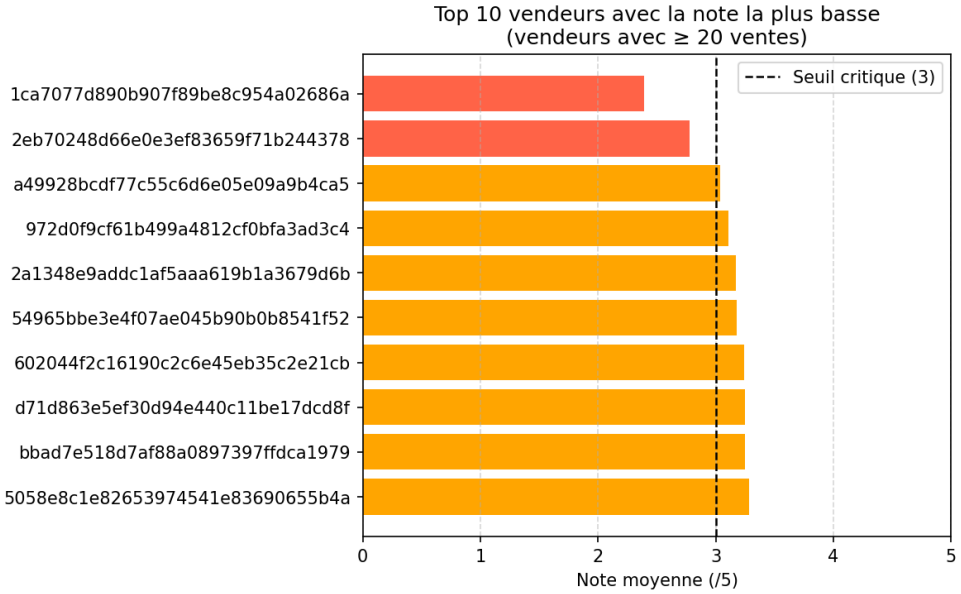


FIGURE 3.4 – Top 10 vendeurs actifs par note moyenne la plus basse

Le deuxième vendeur (2eb70248) est particulièrement préoccupant : avec 185 ventes et 38 851 BRL de CA, il génère un volume important malgré des notes très mauvaises.

3.4 Analyse des catégories de produits

3.4.1 Catégories performantes

Cinq catégories ont à la fois un CA élevé et une note moyenne supérieure à 4 (tableau 3.4).

TABLE 3.4 – Catégories performantes

Catégorie	CA (BRL)	Note moy.	Taux retard
health_beauty	1 229 975	4,23	7,6 %
watches_gifts	1 159 859	4,13	7,4 %
bed_bath_table	1 020 478	4,01	7,5 %
sports_leisure	954 115	4,23	6,6 %
computers_accessories	886 218	4,09	6,4 %

3.4.2 Catégories problématiques

Deux catégories ont une note inférieure à 3,8 ou un taux de retard supérieur à 10 % (tableau 3.5). Elles se distinguent de la moyenne globale et méritent une attention particulière.

TABLE 3.5 – Catégories problématiques

Catégorie	CA (BRL)	Note moy.	Taux retard
office_furniture	267 352	3,65	8,1 %
audio	51 198	3,85	11,9 %

La catégorie *audio* cumule un taux de retard de 11,9 %, le plus élevé parmi toutes les catégories analysées. La catégorie *office_furniture* a la note la plus basse (3,65/5), bien en dessous de la moyenne globale de 4,16.

3.4.3 Catégories à surveiller

Trois catégories ont un CA important (top 30 %) mais une note légèrement en dessous de 4,1 (tableau 3.6). Elles ne sont pas défaillantes mais méritent un suivi régulier pour ne pas basculer en zone problématique.

TABLE 3.6 – Catégories à surveiller

Catégorie	CA (BRL)	Note moy.	Taux retard
bed_bath_table	1 020 478	4,01	7,5 %
computers_accessories	886 218	4,09	6,4 %
furniture_decor	712 811	4,08	7,2 %

3.4.4 Catégories à développer

Trois catégories ont de très bonnes notes mais un CA encore faible : *books_general_interest* (4,54/5, 45 256 BRL), *food_drink* (4,45/5, 14 874 BRL) et *construction_tools* (4,43/5, 15 904 BRL). Ces catégories peuvent être développées sans risque pour la qualité du service, comme le montre la figure 3.5.

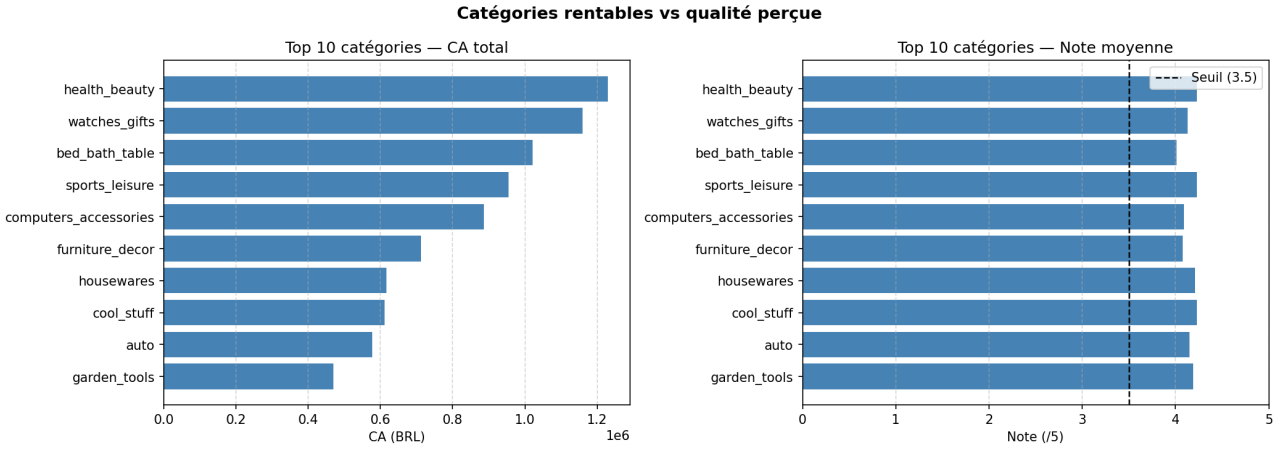


FIGURE 3.5 – Top 10 catégories : chiffre d'affaires et note moyenne comparés

4. Synthèse et recommandations

4.1 Trois problèmes principaux

1. Les retards font baisser fortement la satisfaction. La note passe de 4,29 pour les commandes à temps à 2,27 pour les commandes en retard. Quand le vendeur et le client sont dans des états différents, le délai moyen passe de 7,5 à 14,7 jours.

2. Deux vendeurs représentent un risque pour la plateforme. Ces deux vendeurs ont de mauvaises notes, des taux de retard élevés et un nombre de ventes important. Ils peuvent nuire à l'image générale de la marketplace.

3. Les clients des régions éloignées sont moins bien servis. Trois états concentrent plus de 63 % du CA, mais les clients dans les régions périphériques reçoivent leurs commandes plus tard et avec plus de retards.

4.2 Recommandations

Table 4.1 – Recommandations prioritaires

Priorité	Axe	Action recommandée
1	Logistique régionale	Trouver de nouveaux transporteurs locaux dans les états avec beaucoup de retards. Négocier de meilleurs accords pour les livraisons entre états éloignés.
2	Surveillance des vendeurs	Créer une alerte automatique quand un vendeur actif passe sous 3/5 ou dépasse 15 % de retard. Contacter immédiatement les deux vendeurs identifiés.
3	Délais estimés	Afficher des délais de livraison adaptés à la région du client. Une livraison avant la date prévue donne toujours une meilleure note.
4	Croissance	Promouvoir les catégories à fort potentiel (livres, alimentation, outils) : très bonnes notes et peu de retards.

4.3 KPIs de suivi mensuel

Table 4.2 – Tableau de bord mensuel recommandé

KPI	Valeur actuelle	Objectif
Taux de retard global	6,8 %	$< 5{,}0\,\%$
Note moyenne globale	4,16 / 5	$\geq 4{,}20$ / 5
Vendeurs actifs avec note < 3	2	0
Délai moyen (états à risque)	>15 j	Réduction mensuelle
CA mensuel total	830 000	Croissance continue
Taux de notes faibles (≤ 2)	12,8 %	$< 10{,}0\,\%$

4.4 Limites de l'analyse

Les résultats présentés dans ce rapport sont basés sur des données réelles, mais certaines limites doivent être mentionnées.

— **Période limitée.** Les données couvrent seulement la période 2016–2018. Les conclusions

ne sont pas forcément valables pour la situation actuelle de la marketplace.

— **Commandes non livrées exclues.** Nous avons analysé uniquement les commandes livrées. Les commandes annulées ou en cours ont été retirées, ce qui peut légèrement modifier certains indicateurs comme le taux de retard.

— **Distances approximées.** Nous n'avons pas utilisé les données GPS disponibles dans le dataset. La distance entre vendeur et client a été estimée en comparant les états, ce qui n'est pas toujours précis.

— **Score vendeur simplifié.** Le score vendeur est calculé à partir de la note moyenne et du taux de retard seulement. D'autres facteurs comme les retours produits ou les litiges clients n'ont pas été pris en compte.

— **Pas de données sur les coûts.** Le dataset ne contient pas d'informations sur les marges ou les coûts. Il n'est donc pas possible de mesurer la rentabilité réelle des vendeurs ou des catégories de produits.

— **Identifiants anonymisés.** Les clients et les vendeurs sont anonymisés. On ne peut pas suivre le comportement d'un même client sur plusieurs commandes.

Conclusion

Ce projet nous a permis de faire une analyse complète de la marketplace Olist à partir de neuf tables et 96 252 commandes sur 23 mois. Les résultats montrent une plateforme qui fonctionne bien (13,19 millions de BRL de CA, note moyenne de 4,16/5), mais avec deux problèmes importants : l'impact des retards sur la satisfaction (la note passe de 4,29 à 2,27) et la présence de deux vendeurs à risque.

Nos recommandations visent en priorité à améliorer la logistique dans les régions éloignées et à mettre en place un système de surveillance des vendeurs. Ces deux actions permettraient d'améliorer la satisfaction des clients et la qualité du service. Les catégories à fort potentiel (livres, alimentation, outils) offrent aussi des opportunités de croissance à faible risque.