Université Sultan Moulay Slimane
École Nationale des Sciences Appliquées de Khouribga

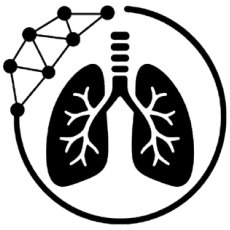
Filière : Informatique et Ingénierie des Données

Module : Méthodologie de projet et veille scientifique

Rapport de projet

Pneumonia Detection from X-rays

Détection automatique de la pneumonie à partir de radiographies thoraciques



Réalisé par :

- Deroui Mouad
- Laaouina Othmane
- Maktou Azeddine
- Nougbolo Godwin Elie

Encadré par :

Pr. Safiny Yazid
Pr. Siham Ahmam

Année universitaire : 2025–2026

Remerciements

Ce projet a été réalisé dans le cadre du module Méthodologie de Projet et Veille Scientifique, filière IID1, à l'ENSA Khouribga.

Nous remercions Pr. Siham AHMAM qui a assuré le cours de ce module. Son enseignement nous a apporté les bases méthodologiques nécessaires et a guidé la rédaction de ce rapport.

Nous remercions également Pr. Safiny Yazid pour l'encadrement technique tout au long des séances de TP. Ses conseils ont orienté nos choix pratiques, en particulier sur la stratégie d'évaluation des modèles et la sélection des métriques adaptées au contexte médical.

Nous remercions enfin l'équipe pédagogique de la filière IID1 pour la formation dispensée cette année, qui nous a permis de mener ce projet à bien.

Résumé

La pneumonie est une infection pulmonaire dont le diagnostic repose en grande partie sur l'analyse de radiographies thoraciques. Cette tâche, longue et dépendante de l'expertise du praticien, est difficile à maintenir dans les contextes où les ressources médicales sont limitées.

Ce rapport présente le développement et la comparaison de deux systèmes de classification automatique d'images médicales. Le premier est un réseau de neurones convolutif construit de zéro (*Custom CNN*). Le second exploite le Transfer Learning à partir du modèle DenseNet121 [1], pré-entraîné sur ImageNet [2]. Les deux modèles ont été entraînés et évalués sur le dataset public *Chest X-Ray Images (Pneumonia)* [3], composé de 5 216 radiographies réparties en deux classes : NORMAL et PNEUMONIA.

Les résultats montrent que DenseNet121 en phase d'extraction de caractéristiques dépasse le CNN sur toutes les métriques : accuracy de 88,9%, F1-score de 0,91 et recall de 0,92 sur la classe PNEUMONIA, contre 81%, 0,84 et 0,81 pour le CNN. La phase de fine-tuning testée sur DenseNet121 n'a pas amélioré ces résultats. Une application web développée avec Streamlit permet de tester les deux modèles de façon interactive.

Mots-clés : pneumonie, radiographie thoracique, CNN, DenseNet121, Transfer Learning, classification binaire, Streamlit.

Table des matières

Remerciements ii

Résumé iii

Table des figures vii

Liste des tableaux viii

Introduction 1

1 Contexte médical et problématique 2
- 1.1 La pneumonie et son diagnostic . . . 2
  - 1.1.1 Une maladie respiratoire grave . . . 2
  - 1.1.2 Rôle des radiographies thoraciques . . . 2
  - 1.1.3 Limites du diagnostic manuel . . . 3
- 1.2 Apport de l'intelligence artificielle . . . 3
  - 1.2.1 Réseaux de neurones convolutifs . . . 3
  - 1.2.2 Transfer Learning avec DenseNet121 . . . 3
- 1.3 Problème à résoudre . . . 4
  - 1.3.1 Formulation de la problématique . . . 4
  - 1.3.2 Questions secondaires . . . 4
- 1.4 Objectifs du projet . . . 4
  - 1.4.1 Objectif principal . . . 4
  - 1.4.2 Objectifs spécifiques . . . 4
- 1.5 Difficultés principales . . . 5
  - 1.5.1 Qualité et déséquilibre des données . . . 5
  - 1.5.2 Overfitting . . . 5
  - 1.5.3 Faux négatifs en contexte médical . . . 5

2 État de l'art 6
- 2.1 Introduction . . . 6
- 2.2 Synthèse des travaux analysés . . . 6
- 2.3 Approches existantes . . . 7
  - 2.3.1 Machine Learning classique . . . 7

2.3.2 CNN avec Transfer Learning . . . 7
2.3.3 Ensemble Learning . . . 7
2.3.4 Vision Transformers . . . 8
2.4 Comparaison critique . . . 8
2.4.1 Tableau récapitulatif . . . 8
2.4.2 Analyse . . . 8
2.5 Positionnement du projet . . . 9
2.5.1 Choix méthodologique . . . 9
2.5.2 Valeur ajoutée . . . 9

3 Méthodologie et implémentation 10
3.1 Environnement d'implémentation . . . 10
3.1.1 Langages et bibliothèques . . . 10
3.1.2 Versions principales . . . 10
3.2 Dataset . . . 11
3.2.1 Présentation et composition . . . 11
3.2.2 Déséquilibre des classes . . . 11
3.2.3 Analyse exploratoire . . . 11
3.3 Prétraitement . . . 11
3.3.1 Redimensionnement et normalisation . . . 11
3.3.2 Data Augmentation . . . 12
3.4 Pipeline général . . . 12
3.5 Modèle Custom CNN . . . 12
3.5.1 Architecture . . . 12
3.5.2 Entraînement . . . 13
3.6 Modèle DenseNet121 . . . 13
3.6.1 Architecture adaptée . . . 13
3.6.2 Entraînement en deux phases . . . 13
3.7 Optimisation du seuil de décision . . . 14
3.8 Métriques d'évaluation . . . 14
3.8.1 Métriques utilisées . . . 14
3.8.2 Pourquoi le Recall est la métrique prioritaire . . . 15
3.9 Application Streamlit . . . 15

4 Résultats, évaluation et comparaison 16
4.1 Introduction . . . 16
4.2 Résultats du Custom CNN . . . 16
4.2.1 Courbes d'entraînement . . . 16
4.2.2 Performances sur le test set . . . 17
4.3 Résultats de DenseNet121 . . . 19
4.3.1 Phase 1 — Feature Extraction . . . 19
4.3.2 Performances sur le test set . . . 20
4.3.3 Phase 2 — Fine-Tuning . . . 21
4.4 Comparaison des modèles . . . 22
4.4.1 Tableau de synthèse . . . 22
4.5 Comparaison avec la littérature . . . 23
4.5.1 Positionnement des résultats . . . 23
4.5.2 Analyse de l'écart . . . 23
4.6 Discussion . . . 23

4.6.1 Facteurs expliquant les performances 23
4.6.2 Limites 24

Conclusion et perspectives **25**

Table des figures

1.1 Exemples de radiographies thoraciques issues du dataset [3] 3

3.1 Pipeline méthodologique de la solution 12
3.2 Architecture du Custom CNN 13
3.3 Architecture DenseNet121 en Transfer Learning 13

4.1 Courbes d'entraînement du Custom CNN 17
4.2 Matrice de confusion — Custom CNN (seuil = 0,7) 18
4.3 Évolution des métriques du CNN selon le seuil 19
4.4 Courbes d'entraînement de DenseNet121 20
4.5 Matrice de confusion — DenseNet121 Feature Extraction (seuil = 0,8) 21
4.6 Comparaison graphique des trois configurations 22

Liste des tableaux

2.1 Synthèse des articles analysés 6
2.2 Comparaison des quatre approches 8

3.1 Versions des outils utilisés 10
3.2 Répartition des données 11
3.3 Impact clinique des erreurs de classification 15

4.1 Historique d'entraînement du Custom CNN (13 epochs) 16
4.2 Rapport de classification du Custom CNN (seuil = 0,7) 17
4.3 Historique d'entraînement de DenseNet121 (15 epochs) 19
4.4 Rapport de classification — DenseNet121 Feature Extraction (seuil = 0,8) . 20
4.5 Comparaison avec les travaux de la littérature 21
4.6 Comparaison finale sur le test set 22
4.7 Comparaison avec les travaux de la littérature 23

Introduction

La pneumonie tue chaque année plusieurs millions de personnes, en particulier des enfants de moins de cinq ans et des personnes âgées. Son diagnostic repose sur l'analyse visuelle de radiographies thoraciques — une tâche qui exige du temps et une expertise que tous les établissements de santé ne peuvent pas toujours mobiliser.

L'intelligence artificielle offre une réponse partielle à ce problème. Les réseaux de neurones convolutifs ont montré, ces dernières années, des performances comparables à celles de radiologues expérimentés sur des tâches de classification d'images médicales [4]. Le Transfer Learning, en particulier, permet d'atteindre de bons résultats même avec des données médicales annotées en quantité limitée.

Ce projet s'inscrit dans cette dynamique. L'objectif est de comparer deux approches de Deep Learning pour la détection automatique de la pneumonie : un CNN entraîné de zéro, et DenseNet121 adapté par Transfer Learning. Le rapport est organisé en quatre chapitres. Le premier pose le contexte médical et la problématique. Le deuxième introduit les fondements théoriques. Le troisième décrit la méthodologie et l'implémentation. Le quatrième présente et analyse les résultats.

Chapitre 1

Contexte médical et problématique

1.1 La pneumonie et son diagnostic

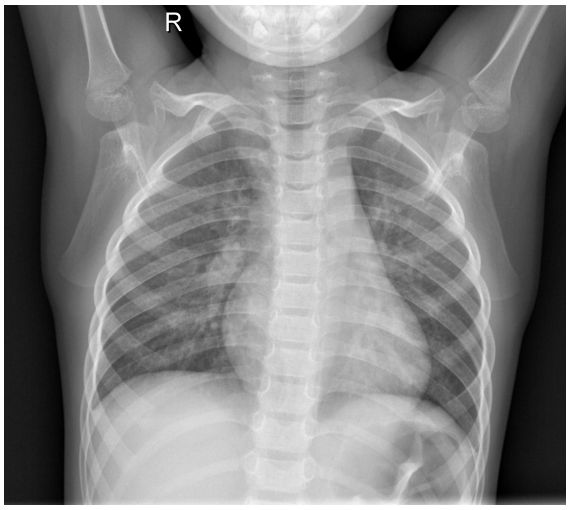
1.1.1 Une maladie respiratoire grave

La pneumonie est une infection qui touche le parenchyme pulmonaire. Elle peut évoluer rapidement vers des formes sévères, en particulier chez les enfants de moins de cinq ans et les personnes immunodéprimées. Son diagnostic précoce est donc déterminant pour la prise en charge du patient.

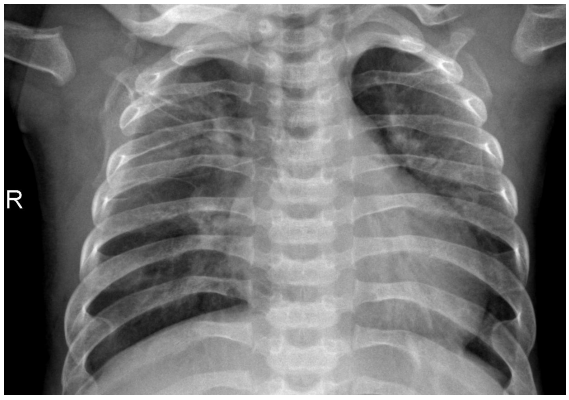
1.1.2 Rôle des radiographies thoraciques

L'analyse des radiographies thoraciques est l'un des outils principaux du diagnostic. Sur une image normale, les champs pulmonaires apparaissent sombres car remplis d'air. En présence d'une pneumonie, certaines zones deviennent opaques ou grisâtres, traduisant une accumulation de liquide ou une infection localisée.

La figure 1.1 illustre cette différence sur deux exemples tirés du dataset utilisé.



(a) Classe NORMAL



(b) Classe PNEUMONIA

FIGURE 1.1 – Exemples de radiographies thoraciques issues du dataset [3]

1.1.3 Limites du diagnostic manuel

L'interprétation d'une radiographie thoracique demande de l'expérience. Dans les hôpitaux à forte affluence, la charge de travail des radiologues peut conduire à des erreurs ou à des retards de diagnostic. Dans certaines régions, l'absence de spécialistes aggrave encore cette situation. Ces contraintes structurelles justifient l'intérêt d'un outil d'aide automatique.

1.2 Apport de l'intelligence artificielle

1.2.1 Réseaux de neurones convolutifs

1.2.1.1 Principe général

Les réseaux de neurones convolutifs (CNN) sont des architectures de Deep Learning conçues pour le traitement des images. Ils apprennent automatiquement des représentations visuelles à partir des données, sans extraction manuelle de caractéristiques. Les premières couches détectent des motifs simples — contours, textures — tandis que les couches profondes combinent ces motifs pour reconnaître des structures plus complexes.

1.2.1.2 Application à l'imagerie médicale

Appliqués aux radiographies thoraciques, les CNN peuvent apprendre à distinguer des poumons sains de poumons infectés à partir d'un ensemble d'images annotées. Plusieurs travaux ont confirmé leur efficacité sur cette tâche [5, 6].

1.2.2 Transfer Learning avec DenseNet121

1.2.2.1 Principe

Le Transfer Learning consiste à réutiliser un modèle pré-entraîné sur un grand dataset pour l'adapter à une nouvelle tâche. Cette approche est particulièrement utile quand les données annotées disponibles sont limitées, comme c'est souvent le cas en imagerie médicale.

1.2.2.2 DenseNet121

DenseNet121 [1] est un réseau pré-entraîné sur ImageNet [2]. Son architecture repose sur des connexions denses entre toutes les couches, ce qui favorise la réutilisation des caractéristiques et limite le nombre de paramètres nécessaires. Plusieurs études ont montré son efficacité sur des tâches de classification de radiographies [6, 7].

1.3 Problème à résoudre

1.3.1 Formulation de la problématique

Le diagnostic manuel de la pneumonie à partir de radiographies thoraciques souffre de plusieurs limitations : variabilité de la qualité des images selon les appareils, subtilité des signes visuels dans les cas légers, et risques d'erreurs liés à la fatigue ou à la surcharge des services. La problématique centrale de ce projet est donc la suivante :

> Comment concevoir un système de Deep Learning capable de classifier automatiquement une radiographie thoracique en NORMAL ou PNEUMONIA, avec un recall suffisamment élevé pour limiter les faux négatifs dans un contexte médical ?

1.3.2 Questions secondaires

Cette problématique soulève plusieurs questions pratiques : comment préparer les images avant l'entraînement ? Quel modèle — CNN from scratch ou Transfer Learning — offre le meilleur compromis entre performance et coût computationnel ? Comment gérer le déséquilibre entre les classes du dataset ? Et quel seuil de décision retenir pour maximiser le recall sur la classe PNEUMONIA ?

1.4 Objectifs du projet

1.4.1 Objectif principal

Développer et comparer deux systèmes de classification automatique de radiographies thoraciques — un CNN personnalisé et DenseNet121 en Transfer Learning — et déployer une application de démonstration.

1.4.2 Objectifs spécifiques

Les objectifs spécifiques sont les suivants : analyser et préparer le dataset, appliquer les étapes de prétraitement, entraîner les deux modèles dans des conditions comparables, évaluer leurs performances avec des métriques adaptées au contexte médical (accuracy, precision, recall, F1-score, AUC), et développer une interface Streamlit permettant de tester une radiographie en temps réel.

1.5 Difficultés principales

1.5.1 Qualité et déséquilibre des données

Les radiographies du dataset ont des dimensions très variables — largeur comprise entre 384 et 2 916 pixels, hauteur entre 127 et 2 663 pixels. Un redimensionnement uniforme est donc indispensable. Par ailleurs, la classe PNEUMONIA représente environ 74% des images d'entraînement, ce qui crée un déséquilibre susceptible de biaiser l'apprentissage vers la classe majoritaire.

1.5.2 Overfitting

Un modèle entraîné sur un dataset médical de taille modérée risque d'apprendre par cœur les exemples d'entraînement sans bien généraliser. La Data Augmentation, le Dropout et l'EarlyStopping ont été utilisés pour limiter ce phénomène.

1.5.3 Faux négatifs en contexte médical

Un faux négatif — une radiographie avec pneumonie classée comme normale — peut retarder la prise en charge du patient avec des conséquences graves. C'est pourquoi le recall de la classe PNEUMONIA est la métrique prioritaire dans ce projet, plus que l'accuracy globale.

Chapitre 2

État de l'art

2.1 Introduction

Automatiser la détection de la pneumonie à partir de radiographies thoraciques est un problème bien étudié dans la littérature. Une revue de dix travaux récents [8] permet de dégager quatre grandes familles de méthodes : le Machine Learning classique, les CNN avec Transfer Learning, l'Ensemble Learning et les Vision Transformers. Cette section présente chaque approche, la compare aux autres, puis situe notre travail par rapport à ces travaux.

2.2 Synthèse des travaux analysés

Le tableau 2.1 regroupe les dix articles retenus lors de la recherche bibliographique.

Table 2.1 – Synthèse des articles analysés

Auteurs	**Année**	**Méthode**	**Accuracy**
Bashar [9]	2024	Vision Transformer	97,61%
Hashmi et al. [6]	2020	Transfer Learning (Ensemble)	≈98%
Al-Rousan et al. [10]	2023	Machine Learning (SVM)	97,58%
Jain et al. [5]	2021	CNN + Transfer Learning (VGG16, ResNet50)	> 90%
Yadav & Jadhav [11]	2022	CNN + Transfer Learning	—
Soltanian et al. [12]	2021	CNN personnalisé	—
Usman et al. [13]	2025	Machine Learning classique	—
Sreenu & Akram [14]	2025	CNN classification	—
Kundu et al. [7]	2021	Ensemble CNN	—

2.3 Approches existantes

2.3.1 Machine Learning classique

2.3.1.1 Principe et représentants

Le Machine Learning classique traite la détection de la pneumonie en deux étapes. D'abord, des caractéristiques sont extraites manuellement de l'image — moyenne, écart-type, entropie, HOG, LBP. Ensuite, un algorithme de classification — SVM, KNN, Random Forest — prend ces caractéristiques en entrée pour produire un diagnostic.

Al-Rousan et al. [10] appliquent cette approche sur un dataset de radiographies pédiatriques et atteignent 97,58% d'accuracy. Usman et al. [13] obtiennent des résultats comparables avec des méthodes similaires.

2.3.1.2 Performances et limites

L'avantage principal de cette famille est sa légèreté computationnelle. En revanche, ses performances dépendent directement de la qualité des caractéristiques choisies manuellement — un mauvais choix de features dégrade immédiatement les résultats. Sur des datasets hétérogènes, ces méthodes généralisent moins bien que les approches Deep Learning.

2.3.2 CNN avec Transfer Learning

2.3.2.1 Principe et représentants

Les réseaux de neurones convolutifs apprennent automatiquement les représentations visuelles pertinentes sans aucune extraction manuelle. Le Transfer Learning renforce cette capacité en initialisant le réseau avec des poids pré-entraînés sur ImageNet [2], évitant ainsi un apprentissage depuis zéro.

Jain et al. [5] comparent VGG16 et ResNet50 sur le dataset Kaggle et montrent que le Transfer Learning réduit le temps d'entraînement tout en maintenant une accuracy supérieure à 90%. Yadav et Jadhav [11] confirment ces observations avec d'autres architectures CNN.

2.3.2.2 Performances et limites

C'est l'approche la plus répandue dans la littérature récente. Elle offre un bon équilibre entre performance, complexité d'implémentation et ressources requises. Son principal risque est l'overfitting quand le fine-tuning est trop agressif sur un dataset de taille limitée.

2.3.3 Ensemble Learning

2.3.3.1 Principe et représentants

L'Ensemble Learning combine plusieurs modèles indépendants pour produire une prédiction finale par vote ou moyenne pondérée. Cette stratégie réduit la variance des erreurs individuelles.

Hashmi et al. [6] combinent cinq CNN pré-entraînés — ResNet18, Xception, InceptionV3, DenseNet121 et MobileNetV2 — et atteignent des performances proches de 98%. Kundu et al.

[7] obtiennent des résultats similaires en combinant GoogLeNet, ResNet18 et DenseNet121, validés sur deux datasets distincts (Kaggle et RSNA).

2.3.3.2 Performances et limites

L'Ensemble Learning produit les meilleures performances absolues de la littérature. Sa complexité opérationnelle est cependant élevée : plusieurs modèles doivent être entraînés séparément, ce qui multiplie le coût en temps, en mémoire et en infrastructure. Ce n'est pas l'approche la plus adaptée à un projet académique avec des ressources limitées.

2.3.4 Vision Transformers

2.3.4.1 Principe et représentants

Les Vision Transformers [9] transposent l'architecture Transformer au traitement d'images. L'image est découpée en patches traités séquentiellement par un mécanisme d'attention multi-têtes. Contrairement aux CNN, cette architecture capture des dépendances spatiales globales dès les premières couches, sans supposer de localité des caractéristiques.

Bashar [9] applique un ViT à la détection de la pneumonie sur des radiographies thoraciques et obtient 97,61% d'accuracy, surpassant plusieurs CNN classiques sur le même dataset.

2.3.4.2 Performances et limites

Les résultats sont compétitifs mais ces modèles exigent de grandes quantités de données et une puissance de calcul importante pour converger correctement. Leur adoption dans des contextes médicaux avec des ressources contraintes reste pour l'instant limitée.

2.4 Comparaison critique

2.4.1 Tableau récapitulatif

TABLE 2.2 – Comparaison des quatre approches

Approche	Accuracy	Complexité	Données	Ressources
ML classique	≈97%	Faible	Peu	Faibles
CNN + Transfer Learning	>90%	Moyenne	Modérée	Moyennes
Ensemble Learning	≈98%	Élevée	Modérée	Élevées
Vision Transformers	≈97%	Élevée	Grande	Élevées

2.4.2 Analyse

Les chiffres élevés du ML classique méritent une nuance. Al-Rousan et al. [10] travaillent sur un dataset pédiatrique homogène où les caractéristiques extraites sont particulièrement discriminantes. Sur des datasets plus hétérogènes, les CNN surpassent systématiquement ces méthodes.

L'Ensemble Learning atteint les meilleures performances absolues, mais son coût opérationnel le rend difficile à déployer dans un environnement académique contraint. Les Vision Transformers sont prometteurs, mais leur convergence exige des volumes de données et des ressources que la majorité des projets médicaux ne peuvent pas mobiliser.

Les CNN avec Transfer Learning représentent le meilleur compromis entre performance, complexité et accessibilité. C'est pourquoi ils dominent la littérature récente sur la détection de la pneumonie.

2.5 Positionnement du projet

2.5.1 Choix méthodologique

Notre travail s'inscrit dans la famille CNN avec Transfer Learning — l'approche la mieux documentée et la plus adaptée aux contraintes d'un projet académique. Plutôt que de reproduire une architecture existante, nous proposons une comparaison directe entre un CNN entraîné from scratch et DenseNet121 [1] en Transfer Learning, sous les mêmes conditions expérimentales.

2.5.2 Valeur ajoutée

La majorité des travaux de la littérature comparent des architectures différentes sans contrôler strictement les conditions expérimentales. Notre protocole maintient les mêmes hyperparamètres, le même dataset et le même processus d'évaluation pour les deux modèles, ce qui rend la comparaison directement interprétable. Le déploiement d'une application Streamlit [15] constitue par ailleurs un livrable opérationnel que peu de travaux académiques produisent.

Chapitre 3

Méthodologie et implémentation

3.1 Environnement d'implémentation

3.1.1 Langages et bibliothèques

Le projet a été implémenté en Python avec TensorFlow/Keras pour la construction et l'entraînement des modèles, NumPy pour la manipulation des tableaux, Matplotlib pour la visualisation, Scikit-learn pour le calcul des métriques, et Streamlit pour l'interface web. Les notebooks ont été exécutés sur Google Colab avec accélération GPU, ce qui a ramené les temps d'entraînement à quelques minutes par epoch.

3.1.2 Versions principales

Table 3.1 – Versions des outils utilisés

Outil	**Version**
Python	3.11
TensorFlow	2.15.0
NumPy	1.26.4
Streamlit	1.32.2

3.2 Dataset

3.2.1 Présentation et composition

3.2.1.1 Source

Le dataset utilisé est le *Chest X-Ray Images (Pneumonia)* [3], disponible publiquement sur Kaggle [16]. Il contient des radiographies thoraciques pédiatriques collectées au Guangzhou Women and Children's Medical Center, organisées en deux classes : NORMAL et PNEUMONIA.

3.2.1.2 Répartition

TABLE 3.2 – Répartition des données

Ensemble	NORMAL	PNEUMONIA	Total
Entraînement (80%)	≈ 1 073	≈ 3 100	4 173
Validation (20%)	≈ 268	≈ 775	1 043
Test	234	390	624
Total	**1 575**	**4 265**	**5 840**

3.2.2 Déséquilibre des classes

La classe PNEUMONIA représente environ 74% des images d'entraînement. Pour compenser ce déséquilibre, des poids de classe ont été calculés avec `compute_class_weight("balanced")` de scikit-learn, donnant 1,91 pour NORMAL et 0,68 pour PNEUMONIA. Ces poids ont été passés au modèle via le paramètre `class_weight` de `model.fit()`.

3.2.3 Analyse exploratoire

Les dimensions originales des images sont très hétérogènes : largeur entre 384 et 2 916 px, hauteur entre 127 et 2 663 px. Ce constat justifie l'étape de redimensionnement uniforme à 224×224 px.

3.3 Prétraitement

3.3.1 Redimensionnement et normalisation

3.3.1.1 Redimensionnement

Toutes les images sont redimensionnées à 224×224 pixels via `tf.keras.utils.image_dataset_from` Ce format est requis par DenseNet121 et assure des entrées de dimension uniforme pour les deux modèles.

3.3.1.2 Normalisation

Les valeurs des pixels, initialement dans $[0, 255]$, sont ramenées dans $[0, 1]$ par une couche `Rescaling(1./255)`. Cette normalisation stabilise les gradients et accélère la convergence.

3.3.2 Data Augmentation

3.3.2.1 Transformations appliquées

La Data Augmentation est appliquée uniquement sur le jeu d'entraînement. Les transformations utilisées sont : retournement horizontal aléatoire, rotation de ±2%, zoom de ±10%, translation horizontale et verticale de ±10%. Pour DenseNet121, une variation aléatoire du contraste a été ajoutée.

3.3.2.2 Objectif

Ces transformations exposent le modèle à des variantes des images qu'il n'a pas vues, ce qui réduit le risque de mémorisation du dataset d'entraînement.

3.4 Pipeline général

La figure 3.1 résume les étapes du système développé.

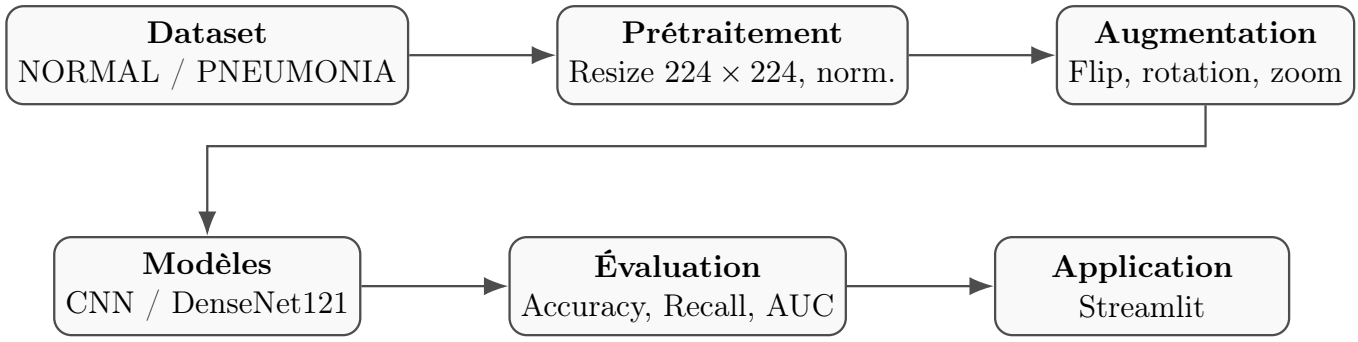


FIGURE 3.1 – Pipeline méthodologique de la solution

3.5 Modèle Custom CNN

3.5.1 Architecture

3.5.1.1 Blocs convolutifs

Le CNN est composé de quatre blocs convolutifs successifs, chacun associant une couche `Conv2D` (activation ReLU, `padding="same"`) à une couche `MaxPooling2D`. Le nombre de filtres double à chaque bloc : 32, 64, 128, 256. Un `Dropout(0.3)` est appliqué après le dernier bloc.

3.5.1.2 Tête de classification

Après les blocs convolutifs, une couche `GlobalAveragePooling2D` réduit les cartes de caractéristiques à un vecteur de dimension 256, suivi d'une couche Dense de 128 neurones, d'un second `Dropout(0.3)`, et d'une sortie sigmoid. Le modèle totalise 421 441 paramètres entraînables.



FIGURE 3.2 – Architecture du Custom CNN

3.5.2 Entraînement

3.5.2.1 Paramètres

Le modèle est compilé avec Adam (lr = 10^{-4}) et Binary Crossentropy. L'entraînement est limité à 25 epochs avec batch size 32.

3.5.2.2 Callbacks

Deux callbacks ont été utilisés : `EarlyStopping` (surveillance de la val_loss, patience = 5, restauration des meilleurs poids) et `ModelCheckpoint`. En pratique, l'entraînement s'est arrêté à la 13e epoch.

3.6 Modèle DenseNet121

3.6.1 Architecture adaptée

3.6.1.1 Base pré-entraînée

La base DenseNet121 [1], chargée sans sa tête originale (`include_top=False`), produit une carte de caractéristiques de dimension $7 \times 7 \times 1024$. Elle compte 7 037 504 paramètres, tous gelés en phase de Feature Extraction.

3.6.1.2 Tête de classification ajoutée

Une tête de classification a été ajoutée : `GlobalAveragePooling2D` → `Dense(128, relu)` → `Dropout(0.3)` → sortie sigmoid. En phase de Feature Extraction, seuls 131 329 paramètres sont entraînables.

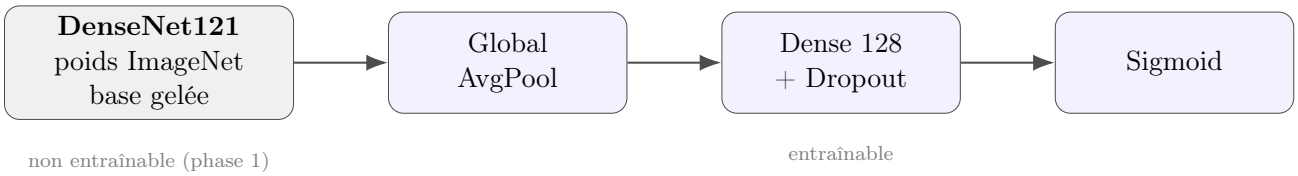


FIGURE 3.3 – Architecture DenseNet121 en Transfer Learning

3.6.2 Entraînement en deux phases

3.6.2.1 Phase 1 — Feature Extraction

La base DenseNet121 est gelée. Seule la tête est entraînée avec Adam (lr = 10^{-4}) sur 15 epochs. Le meilleur modèle est obtenu à l'epoch 14 (val_loss = 0.1424).

3.6.2.2 Phase 2 — Fine-Tuning

Les 127 dernières couches (sur 427) sont dégelées et réentraînées avec lr = 10^{-5}. Un callback `ReduceLROnPlateau` (factor = 0.2, patience = 2) réduit le learning rate si la validation loss stagne. L'entraînement s'est arrêté à la 6e epoch.

3.7 Optimisation du seuil de décision

Un balayage du seuil de 0,1 à 0,9 (pas de 0,1) a été effectué sur le test set pour les deux modèles. Le seuil retenu est celui qui maximise le F1-score tout en maintenant un recall acceptable sur la classe PNEUMONIA.

3.8 Métriques d'évaluation

3.8.1 Métriques utilisées

3.8.1.1 Accuracy

L'accuracy mesure la proportion totale de prédictions correctes sur l'ensemble du test set :

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{3.1}$$

C'est la métrique la plus intuitive, mais elle peut être trompeuse sur des datasets déséquilibrés. Avec 390 images PNEUMONIA contre 234 NORMAL, un modèle qui prédirait PNEUMONIA sur toutes les images atteindrait une accuracy artificielle de 62,5% sans rien apprendre.

3.8.1.2 Precision

$$Precision = \frac{TP}{TP + FP} \tag{3.2}$$

La precision indique quelle proportion des images classées PNEUMONIA est réellement atteinte de pneumonie. Une precision faible signifie que le modèle génère beaucoup de faux positifs — des patients sains envoyés inutilement vers des examens complémentaires.

3.8.1.3 Recall

$$Recall = \frac{TP}{TP + FN} \tag{3.3}$$

Le recall mesure la capacité du modèle à identifier tous les vrais cas de pneumonie. Un recall de 0,80 signifie que 20% des pneumonies réelles sont manquées par le modèle.

3.8.1.4 F1-score

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \tag{3.4}$$

Le F1-score combine precision et recall en un seul indicateur. Il est particulièrement utile pour comparer deux modèles sur un dataset déséquilibré, car il pénalise à la fois les faux positifs et les faux négatifs.

3.8.1.5 AUC-ROC

L'AUC (Area Under the ROC Curve) mesure la capacité de séparation du modèle entre les deux classes, indépendamment du seuil de décision. Une AUC de 1,0 correspond à une séparation parfaite ; une AUC de 0,5 correspond à une prédiction aléatoire. Cette métrique est utile pour comparer des modèles sans se préoccuper du seuil retenu.

3.8.2 Pourquoi le Recall est la métrique prioritaire

Dans un contexte de diagnostic médical, les erreurs n'ont pas toutes le même poids clinique. Un faux positif — classer une radiographie normale comme PNEUMONIA — entraîne des examens complémentaires inutiles et une anxiété pour le patient, mais ne met pas sa vie en danger. Un faux négatif — classer une pneumonie comme NORMAL — peut retarder la prise en charge et exposer le patient à des complications graves.

Cette asymétrie justifie de privilégier le recall sur la precision pour la classe PNEUMONIA. Un modèle avec un recall de 0,95 et une precision de 0,75 est cliniquement préférable à un modèle avec un recall de 0,80 et une precision de 0,90. C'est ce raisonnement qui a guidé le choix du seuil de décision pour chaque modèle.

TABLE 3.3 – Impact clinique des erreurs de classification

Type d'erreur	**Prédiction**	**Conséquence clinique**
Faux positif	NORMAL → PNEUMONIA	Examens inutiles, anxiété
Faux négatif	PNEUMONIA → NORMAL	Retard de prise en charge

3.9 Application Streamlit

Une interface web développée avec Streamlit [15] permet à l'utilisateur de téléverser une radiographie, de choisir le modèle, et d'obtenir le diagnostic prédit avec un score de confiance, une jauge de risque et une comparaison des deux modèles. Cette application constitue une démonstration pratique du système et ne remplace pas un diagnostic médical professionnel.

Chapitre 4

Résultats, évaluation et comparaison

4.1 Introduction

Ce chapitre présente les résultats expérimentaux obtenus sur le test set de 624 images (234 NORMAL, 390 PNEUMONIA). Trois configurations sont évaluées : le Custom CNN, DenseNet121 en Feature Extraction et DenseNet121 après Fine-Tuning. Les résultats sont ensuite comparés aux travaux de la littérature présentés au chapitre précédent.

4.2 Résultats du Custom CNN

4.2.1 Courbes d'entraînement

4.2.1.1 Historique des métriques

Table 4.1 – Historique d'entraînement du Custom CNN (13 epochs)

Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1	0,5913	73,74%	0,5595	76,13%
3	0,5418	73,40%	0,5099	75,55%
6	0,3653	83,06%	0,2980	87,54%
8	0,3162	85,09%	**0,2744**	**88,49%**
13	0,2796	87,13%	0,3764	80,06%

4.2.1.2 Analyse

Le meilleur modèle est obtenu à l'epoch 8 (val_loss = 0,2744). Au-delà, la val_loss repart à la hausse alors que la train_loss continue de diminuer — signe classique d'overfitting. La val_accuracy chute de 88,49% à 80,06% entre l'epoch 8 et l'epoch 13, confirmant que le modèle mémorise les données d'entraînement sans améliorer sa généralisation.

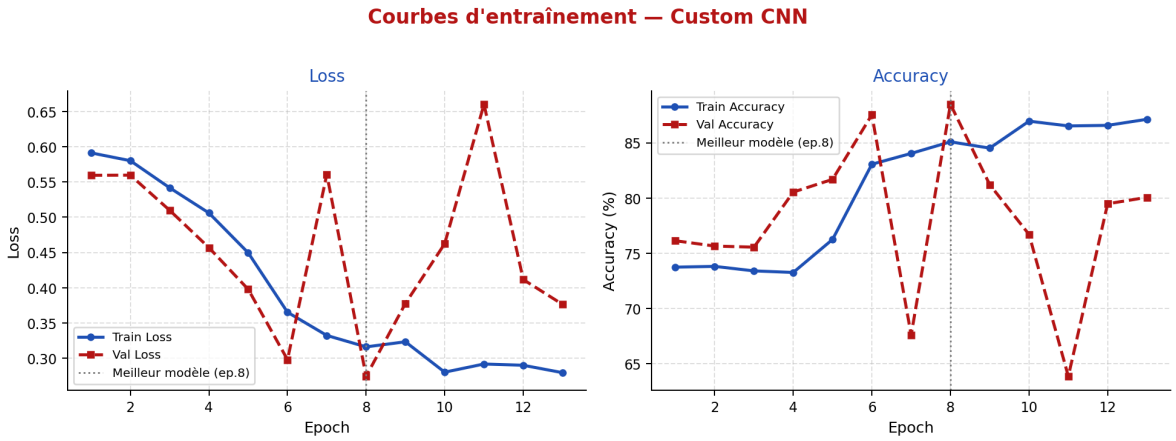


FIGURE 4.1 – Courbes d'entraînement du Custom CNN

4.2.2 Performances sur le test set

4.2.2.1 Rapport de classification

TABLE 4.2 – Rapport de classification du Custom CNN (seuil = 0,7)

Classe	Precision	Recall	F1-score	Support
NORMAL	0,72	0,81	0,76	234
PNEUMONIA	0,88	0,81	0,84	390
Accuracy		81% — 624 images		
AUC		0,8938		

4.2.2.2 Matrice de confusion

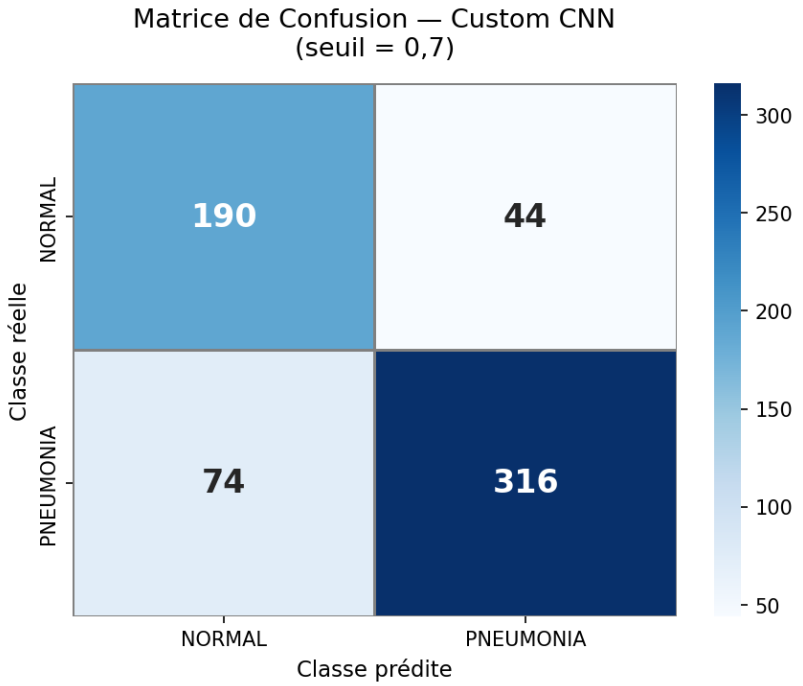


FIGURE 4.2 – Matrice de confusion — Custom CNN (seuil = 0,7)

Sur les 234 images NORMAL, le modèle en classe correctement 190 et en prédit incorrectement 44 comme PNEUMONIA (faux positifs). Sur les 390 images PNEUMONIA, 316 sont correctement détectées et 74 sont manquées (faux négatifs). Ces 74 faux négatifs représentent le point le plus faible du modèle dans un contexte médical.

4.2.2.3 Analyse du seuil

Un balayage des seuils de 0,1 à 0,9 montre que le F1-score maximal est atteint à 0,6 (F1 = 0,859). Le seuil de 0,7 a été retenu pour favoriser la precision (0,88) — un choix discutable dans un contexte médical où un recall élevé est prioritaire.

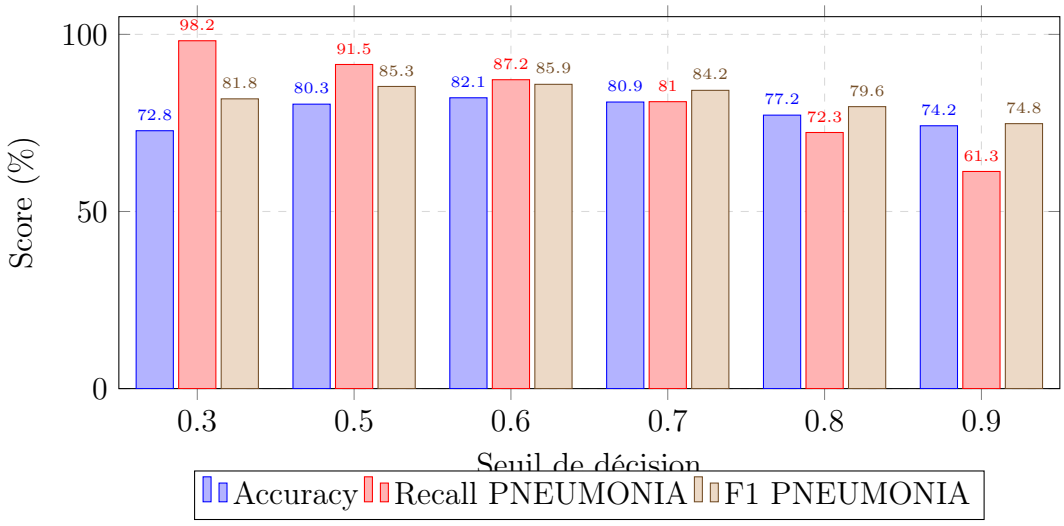


FIGURE 4.3 – Évolution des métriques du CNN selon le seuil

4.3 Résultats de DenseNet121

4.3.1 Phase 1 — Feature Extraction

4.3.1.1 Historique des métriques

TABLE 4.3 – Historique d'entraînement de DenseNet121 (15 epochs)

Epoch	Train Loss	Train Acc	Val Loss	Val Acc
1	0,5004	76,40%	0,2615	92,04%
2	0,3322	85,62%	0,1980	93,67%
5	0,2350	90,08%	0,1794	92,62%
8	0,2083	91,61%	0,1512	93,86%
14	0,1866	92,72%	**0,1424**	**94,25%**
15	0,1958	92,14%	0,1492	93,86%

4.3.1.2 Analyse

Dès l'epoch 1, la val_accuracy dépasse 92% — preuve directe de l'efficacité du Transfer Learning. Le modèle bénéficie des représentations visuelles déjà apprises sur ImageNet et n'a besoin que d'adapter sa tête de classification. La convergence est stable sur les 15 epochs, sans signe d'overfitting.

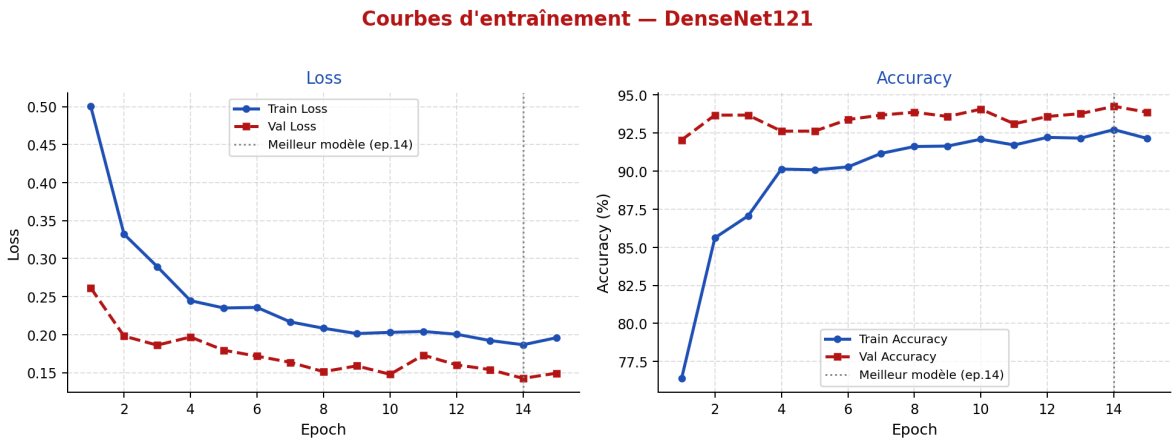


FIGURE 4.4 – Courbes d'entraînement de DenseNet121

4.3.2 Performances sur le test set

4.3.2.1 Rapport de classification

TABLE 4.4 – Rapport de classification — DenseNet121 Feature Extraction (seuil = 0,8)

Classe	Precision	Recall	F1-score	Support
NORMAL	0,86	0,84	0,85	234
PNEUMONIA	0,90	0,92	0,91	390
Accuracy		88,9% — 624 images		
AUC		0,9848		

4.3.2.2 Matrice de confusion

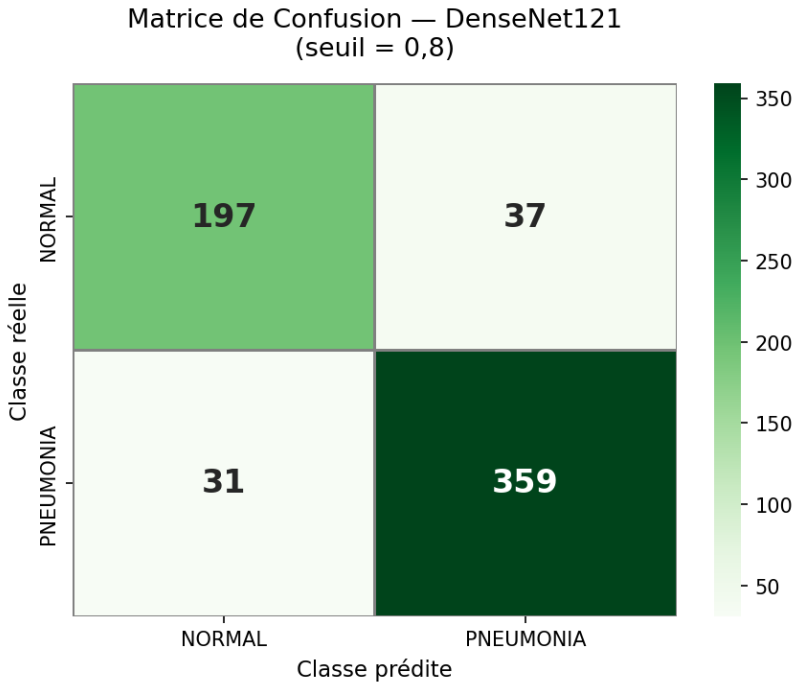


FIGURE 4.5 – Matrice de confusion — DenseNet121 Feature Extraction (seuil = 0,8)

DenseNet121 réduit significativement les faux négatifs : sur 390 cas de pneumonie, seulement 31 sont manqués contre 74 pour le CNN. Les faux positifs augmentent légèrement — 38 images normales classées PNEUMONIA — mais ce compromis est acceptable dans un contexte clinique où le coût d'un faux négatif est supérieur à celui d'un faux positif.

4.3.3 Phase 2 — Fine-Tuning

4.3.3.1 Déroulement

Le Fine-Tuning s'est arrêté à la 6e epoch. Le callback `ReduceLROnPlateau` a réduit le learning rate à deux reprises : epoch 3 ($10^{-5} \rightarrow 2 \times 10^{-6}$) et epoch 5 ($2 \times 10^{-6} \rightarrow 4 \times 10^{-7}$).

4.3.3.2 Performances et interprétation

TABLE 4.5 – Comparaison avec les travaux de la littérature

Auteurs	Méthode	Accuracy
Al-Rousan et al. (2023) [10]	ML classique (SVM)	97,58%
Hashmi et al. (2020) [6]	Ensemble CNN	≈98%
Bashar (2024) [9]	Vision Transformer	97,61%
Jain et al. (2021) [5]	CNN + Transfer Learning	>90%
Notre CNN	From scratch	81%
Notre DenseNet121	Transfer Learning	88,9%

Le Fine-Tuning dégrade légèrement les résultats : le recall sur PNEUMONIA passe de 0,92 à 0,87. Les représentations apprises sur ImageNet étaient déjà suffisamment générales pour cette tâche — le dégel des couches profondes n'a fait qu'introduire un léger surapprentissage sur le dataset d'entraînement.

4.4 Comparaison des modèles

4.4.1 Tableau de synthèse

TABLE 4.6 – Comparaison finale sur le test set

Modèle	Accuracy	F1 PNEUMONIA	Recall PNEUMONIA	AUC
Custom CNN	81%	0,84	0,81	0,894
DenseNet121 (FE)	**88,9%**	**0,91**	**0,92**	**0,985**
DenseNet121 (FT)	88%	0,90	0,87	—

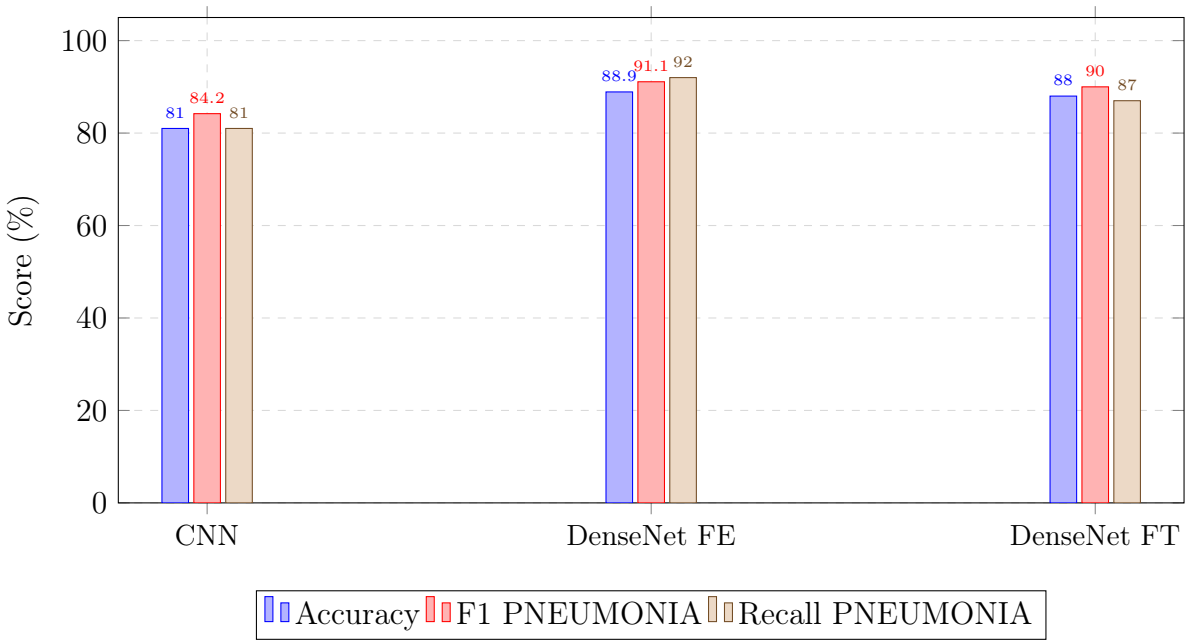


FIGURE 4.6 – Comparaison graphique des trois configurations

4.5 Comparaison avec la littérature

4.5.1 Positionnement des résultats

TABLE 4.7 – Comparaison avec les travaux de la littérature

Auteurs	Méthode	Accuracy	Année
Al-Rousan et al. [10]	ML classique (SVM)	97,58%	2023
Hashmi et al. [6]	Ensemble CNN	≈98%	2020
Bashar [9]	Vision Transformer	97,61%	2024
Jain et al. [5]	CNN + Transfer Learning	>90%	2021
Notre CNN	From scratch	81%	2026
Notre DenseNet121	Transfer Learning	88,9%	2026

4.5.2 Analyse de l'écart

Nos résultats sont inférieurs aux meilleures performances publiées. Cet écart s'explique par plusieurs facteurs cumulés. Les études qui atteignent 97-98% utilisent soit des techniques d'Ensemble Learning combinant plusieurs modèles [6, 7], soit des architectures plus récentes comme les Vision Transformers [9] entraînées sur des datasets plus larges.

Le résultat de 97,58% d'Al-Rousan et al. [10] avec du ML classique mérite une nuance : il est obtenu sur un dataset pédiatrique homogène où les caractéristiques extraites manuellement sont particulièrement discriminantes, ce qui n'est pas représentatif de conditions cliniques générales.

Nos 88,9% avec DenseNet121 en Feature Extraction restent cohérents avec les travaux utilisant une seule architecture en Transfer Learning, comme Jain et al. [5] qui rapportent des accuracy supérieures à 90% avec VGG16 et ResNet50 dans des conditions proches des nôtres.

4.6 Discussion

4.6.1 Facteurs expliquant les performances

4.6.1.1 Architecture et Transfer Learning

L'écart de 8 points entre le CNN (81%) et DenseNet121 (88,9%) s'explique principalement par les poids pré-entraînés sur ImageNet. Avec seulement 4 173 images d'entraînement, un CNN from scratch ne peut pas apprendre des représentations visuelles aussi robustes que celles que DenseNet121 a acquises sur 1,2 million d'images. La val_accuracy de DenseNet121 dépasse 92% dès la première epoch — un gain immédiat impossible à atteindre en partant de zéro.

4.6.1.2 Analyse des erreurs

Le Custom CNN génère plus de faux positifs sur la classe NORMAL (precision = 0,72 contre 0,86 pour DenseNet121). Plus critique, il manque environ 19% des cas de pneumonie

(recall = 0,81), contre 8% pour DenseNet121 (recall = 0,92). Dans un contexte clinique, cette différence est significative.

4.6.2 Limites

4.6.2.1 Dataset unique

Les deux modèles ont été entraînés et testés exclusivement sur le dataset Kaggle [3]. Leurs performances sur des images provenant d'autres équipements ou d'autres établissements hospitaliers ne sont pas garanties.

4.6.2.2 Coût computationnel

Le Custom CNN (421 441 paramètres) est nettement plus léger que DenseNet121 (7 168 833 paramètres au total). Dans un contexte de déploiement embarqué ou sur des appareils à ressources limitées, cette différence peut constituer un critère de choix décisif.

4.6.2.3 Interprétabilité

Les décisions des deux modèles restent opaques pour un clinicien. L'intégration de Grad-CAM permettrait de visualiser les zones pulmonaires ayant influencé la prédiction, mais cette fonctionnalité dépasse le cadre de ce projet.

Conclusion et perspectives

Ce projet confirme que le Transfer Learning constitue une stratégie efficace pour la classification d'images médicales en contexte de données limitées. Avec seulement 131 329 paramètres entraînés lors de la phase d'extraction de caractéristiques, DenseNet121 dépasse le CNN personnalisé sur toutes les métriques, y compris le recall de la classe PNEUMONIA — la métrique la plus critique pour limiter les faux négatifs.

Le fine-tuning, contrairement à ce qu'on pourrait attendre, a légèrement dégradé les performances. Cela suggère que les représentations apprises par DenseNet121 sur ImageNet sont déjà suffisamment générales pour s'adapter à des radiographies thoraciques sans nécessiter de réentraînement profond. Les résultats obtenus confirment que le Transfer Learning constitue une solution pertinente pour le développement d'outils d'aide au diagnostic médical à partir de radiographies thoraciques, même dans un contexte académique avec des données et des ressources limitées.

Perspectives

Plusieurs pistes méritent d'être explorées pour prolonger ce travail. L'intégration de Grad-CAM dans l'application Streamlit permettrait de visualiser les zones pulmonaires influençant la décision du modèle, ce qui renforcerait la confiance des praticiens. Une extension vers la classification multi-classes — pneumonie bactérienne contre virale — constituerait une évolution naturelle. Enfin, une validation sur des données hospitalières diversifiées serait indispensable avant toute utilisation clinique réelle.

Bibliographie

[1] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, "Densely connected convolutional networks," *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 4700–4708, 2017.

[2] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "Imagenet : A large-scale hierarchical image database," in *2009 IEEE Conference on Computer Vision and Pattern Recognition*, pp. 248–255, IEEE, 2009.

[3] D. S. Kermany, M. Goldbaum, W. Cai, C. C. S. Valentim, H. Liang, S. L. Baxter, A. McKeown, G. Yang, X. Wu, F. Yan, *et al.*, "Identifying medical diagnoses and treatable diseases by image-based deep learning," *Cell*, vol. 172, no. 5, pp. 1122–1131, 2018.

[4] G. Litjens, T. Kooi, B. E. Bejnordi, A. A. A. Setio, F. Ciompi, M. Ghafoorian, J. A. W. M. Van Der Laak, B. Van Ginneken, and C. I. Sánchez, "Deep learning in medical image analysis," *Medical Image Analysis*, vol. 42, pp. 60–88, 2017.

[5] G. Jain, D. Mittal, D. Thakur, and M. K. Mittal, "A deep learning approach for pneumonia detection from chest x-ray images," *Pattern Recognition Letters*, vol. 142, pp. 76–82, 2021.

[6] M. F. Hashmi, S. Katiyar, A. G. Keskar, N. D. Bokde, and Z. W. Geem, "Efficient pneumonia detection in chest xray images using deep transfer learning," *Diagnostics*, vol. 10, no. 6, p. 417, 2020.

[7] R. Kundu, R. Das, Z. W. Geem, G.-T. Han, and R. Sarkar, "Pneumonia detection in chest x-ray images using an ensemble of deep learning models," *PLOS ONE*, vol. 16, no. 9, p. e0256630, 2021.

[8] M. F. Hashmi *et al.*, "Deep learning survey for pneumonia detection in chest x-ray images," *Diagnostics / Survey*, 2021.

[9] A. Bashar, "Efficient pneumonia detection using vision transformers on chest x-rays," *Scientific Reports*, 2024.

[10] S. J. Al-Rousan, S. S. Al-Rousan, and M. Al-Rousan, "A machine learning approach on chest x-rays for pediatric pneumonia detection," *Digital Health*, vol. 9, 2023.

[11] N. Yadav and N. Jadhav, "Pneumonia detection using transfer learning and cnn models," *Journal Placeholder*, 2022.

[12] A. Soltanian and Others, "Deep learning approach for medical image classification," *Journal Name*, vol. X, no. Y, pp. ZZZ–ZZZ, 2021.

[13] N. Usman and Others, "Machine learning methods for pneumonia detection," *Journal Placeholder*, 2025.

[14] N. Sreenu and N. Akram, "Deep learning based pneumonia classification," *Journal Placeholder*, 2025.

[15] Streamlit Inc., "Streamlit : A faster way to build and share data apps." Online, 2024. https ://streamlit.io/.

[16] P. Mooney, "Chest x-ray images (pneumonia)." Kaggle Dataset, 2018. Available at : https ://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia.